BỘ GIÁO DỤC VÀ ĐÀO TẠO
ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN
KHOA HỆ THỐNG THÔNG TIN

BÁO CÁO ĐỒ ÁN MÔN HỌC
MÔN HỌC: ĐIỆN TOÁN ĐÁM MÂY (CLOUD COMPUTING)

ĐỀ TÀI:

MLOPS - XÂY DỰNG HỆ THỐNG DỰ ĐOÁN KHÁCH HÀNG RỜI BỎ DỊCH VỤ (CUSTOMER CHURN PREDICTION)

ENTERPRISE MLOPS LEVEL 2 PLATFORM FOR REAL-TIME CUSTOMER CHURN PREDICTION AND DATA DRIFT MONITORING

NGÀNH: HỆ THỐNG THÔNG TIN

GIẢNG VIÊN HƯỚNG DẪN: ThS. HÀ LÊ HOÀI TRUNG
CÁN BỘ PHẢN BIỆN: QUÝ THẦY/CÔ HỘI ĐỒNG BỘ MÔN
SINH VIÊN THỰC HIỆN: NGUYỄN TRỌNG KHỞI - MSSV: 22520695
LỚP: HTTT2022 - KHÓA HỌC: KHÓA 2022 - 2026

TP. HỒ CHÍ MINH, THÁNG 09 NĂM 2026

PHIẾU NHẬN XÉT CỦA CÁN BỘ HƯỚNG DẪN

Họ và tên Cán bộ hướng dẫn: ThS. HÀ LÊ HOÀI TRUNG

Sinh viên thực hiện: NGUYỄN TRỌNG KHỞI - MSSV: 22520695 - Lớp: HTTT2022

Tên đề tài: MLOPS - XÂY DỰNG HỆ THỐNG DỰ ĐOÁN KHÁCH HÀNG RỜI BỎ DỊCH VỤ (CUSTOMER CHURN PREDICTION)

1. Tinh thần, thái độ làm việc và tính chủ động của sinh viên:

.....

.....

.....

.....

2. Đánh giá về khối lượng, tiến độ và chất lượng sản phẩm MLOps:

.....

.....

.....

.....

3. Kết quả thử nghiệm trên dữ liệu lớn (442k bản ghi) và tối ưu Optuna:

.....

.....

.....

.....

4. Điểm đánh giá kết luận: ..... / 10.0 điểm

(Bằng chữ: .....)

TP. Hồ Chí Minh, ngày ..... tháng ..... năm 2026

Cán bộ hướng dẫn

(Ký và ghi rõ họ tên)

ThS. Hà Lê Hoài Trung

PHIẾU NHẬN XÉT CỦA CÁN BỘ PHẢN BIỆN

Họ và tên Cán bộ phản biện: .....

Sinh viên thực hiện: NGUYỄN TRỌNG KHỞI - MSSV: 22520695

Tên đề tài: MLOPS - XÂY DỰNG HỆ THỐNG DỰ ĐOÁN KHÁCH HÀNG RỜI BỎ DỊCH VỤ (CUSTOMER CHURN PREDICTION)

1. Đánh giá tính mới, tính thực tiễn và độ hoàn thiện mã nguồn:

.....

.....

.....

.....

2. Câu hỏi chất vấn phản biện dành cho sinh viên:

.....

.....

.....

.....

3. Điểm đánh giá phản biện: ..... / 10.0 điểm

(Bằng chữ: .....)

TP. Hồ Chí Minh, ngày ..... tháng ..... năm 2026

Cán bộ phản biện

(Ký và ghi rõ họ tên)

THÔNG TIN HỘI ĐỒNG BẢO VỆ ĐỒ ÁN

Hội đồng chấm bảo vệ đồ án môn học, thành lập theo Quyết định số 485/QĐ-ĐHCNTT ngày 15 tháng 08 năm 2026 của Hiệu trưởng Trường Đại học Công nghệ Thông tin.

Vai Trò	**Họ và Tên**	**Đơn Vị Công Tác**
Chủ tịch Hội đồng	ThS. Hà Lê Hoài Trung	Khoa Hệ thống Thông tin - UIT
Thư ký Hội đồng	ThS. Giảng viên Bộ môn	Khoa Hệ thống Thông tin - UIT
Ủy viên Phản biện	TS. Cán bộ Phản biện	Khoa Khoa học Máy tính - UIT

LỜI CAM ĐOAN

Tôi xin cam đoan đây là công trình nghiên cứu và hiện thực đồ án thực tế của riêng tôi dưới sự hướng dẫn khoa học của ThS. Hà Lê Hoài Trung. Toàn bộ mã nguồn, dữ liệu thực nghiệm (442,211 bản ghi duy nhất sau khi khử trùng lặp và làm sạch), các mô hình học máy được tinh chỉnh siêu tham số bằng Optuna, kho lưu trữ đặc trưng Feast Feature Store và hệ thống giám sát trôi dạt dữ liệu Evidently AI đều được cài đặt, huấn luyện và kiểm thử thực tế trên máy trạm máy chủ và dịch vụ đám mây.

Các số liệu và kết quả trình bày trong báo cáo là hoàn toàn trung thực, khách quan và có thể tái lập 100%. Mọi sự tham khảo từ các công trình nghiên cứu khoa học quốc tế giai đoạn 2024 - 2026, các kho mã nguồn mở uy tín trên GitHub và quy chuẩn Rubric của Khoa đều được trích dẫn nguồn gốc rõ ràng theo định dạng quy chuẩn IEEE.

TP. Hồ Chí Minh, ngày 22 tháng 09 năm 2026
Sinh viên thực hiện
(Ký và ghi rõ họ tên)

Nguyễn Trọng Khởi

LỜI CẢM ƠN

Lời đầu tiên, em xin bày tỏ lòng biết ơn sâu sắc và chân thành nhất đến ThS. Hà Lê Hoài Trung - Giảng viên hướng dẫn môn học Điện toán Đám mây tại Trường Đại học Công nghệ Thông tin - ĐHQG-HCM, Thầy đã tận tình truyền đạt kiến thức chuyên sâu về hạ tầng đám mây, kiến trúc phân tán và định hướng nghiên cứu quý báu trong suốt quá trình thực hiện đề tài.

Em cũng xin trân trọng cảm ơn Quý Thầy/Cô Khoa Hệ thống Thông tin đã trang bị cho em nền tảng kiến thức vững vàng về cơ sở dữ liệu, phân tích dữ liệu lớn và quy trình phát triển phần mềm chuẩn mực.

Đồng thời, em xin gửi lời cảm ơn chân thành đến cộng đồng mã nguồn mở quốc tế (các dự án Feast, MLflow, Optuna, Evidently AI, FastAPI, Scikit-learn, XGBoost, LightGBM) và các tác giả của những công trình nghiên cứu khoa học tiên phong giai đoạn 2024 - 2026 đã chia sẻ các tri thức nền tảng vô giá giúp đề tài đạt được độ hoàn thiện công nghệ cao nhất.

Sinh viên thực hiện

Nguyễn Trọng Khởi

TÓM TẮT ĐỀ TÀI

Trong nền kinh tế số và thị trường dịch vụ định kỳ cạnh tranh cao, việc chủ động dự đoán nguy cơ khách hàng rời bỏ dịch vụ (Customer Churn) là bài toán chiến lược quyết định sự sống còn và khả năng tối ưu hóa lợi nhuận của doanh nghiệp viễn thông. Đồ án tập trung thiết kế và triển khai toàn diện nền tảng ChurnGuard MLOps đạt cấp độ trưởng thành Level 2 (Continuous Training & Automated Pipeline), giải quyết triệt để hai thách thức cố hữu trong môi trường sản xuất: lệch pha đặc trưng giữa huấn luyện và suy luận (Training-Serving Skew) và sự suy giảm độ chính xác theo thời gian do biến động phân phối dữ liệu (Data Drift / Concept Drift).

Hệ thống tích hợp Feast Feature Store theo kiến trúc kho kép (Offline Snappy Parquet phục vụ huấn luyện theo thời điểm Point-in-Time, Online SQLite cho truy xuất suy luận thời gian thực với độ trễ dưới 2ms); quản lý vòng đời và Model Registry bằng MLflow; tự động hóa phiên bản dữ liệu và quy trình tái lập với DVC; và cung cấp REST API hiệu năng cao trên nền FastAPI hỗ trợ giải thích trực tiếp từng quyết định suy luận bằng SHAP TreeExplainer. Thực nghiệm trên 442,211 bản ghi khách hàng sạch với kiểm định chéo 5-Fold Stratified Cross-Validation và tối ưu siêu tham số Bayes bằng Optuna (12 trials) đã đưa mô hình XGBoost đạt ROC-AUC 0.9990. Báo cáo cũng chỉ ra đặc thù dữ liệu tổng hợp Kaggle và đề xuất các giải pháp kiểm định an toàn dữ liệu định hướng triển khai thực tế.

Từ khóa: *MLOps, Dự đoán Churn, Feature Store, Feast, MLflow, Data Drift, Evidently AI, Tối ưu Optuna, SHAP XAI, Điện toán Đám mây.*

ABSTRACT

In the modern subscription-based digital economy, proactive customer churn prediction represents a critical capability for optimizing customer lifetime value and enterprise retention economics. This thesis designs and implements an enterprise-grade MLOps Level 2 platform named ChurnGuard, specifically addressing two fundamental production bottlenecks: Training-Serving Skew and progressive model decay caused by Data and Concept Drift.

The architecture seamlessly incorporates Feast Feature Store with dual-store capability (Snappy Parquet for offline point-in-time training and SQLite for low-latency real-time online inference under 2ms), automated experiment tracking and Model Registry through MLflow, reproducible data versioning via DVC, and production REST API serving built on FastAPI featuring real-time feature attribution via SHAP TreeExplainer. Empirical validation across 442,211 deduplicated customer records using 5-Fold Stratified Cross Validation and Optuna Bayesian optimization (12 trials) yields a robust ROC-AUC of 0.9990 for XGBoost Champion. Furthermore, the thesis provides deep statistical analysis into synthetic data artifacts and formalizes automated retraining trigger mechanisms for resilient cloud operations.

Keywords: *MLOps, Customer Churn Prediction, Feature Store, Feast, MLflow, Data Drift, Evidently AI, Optuna Tuning, Explainable AI, Cloud Computing.*

MỤC LỤC TỔNG QUAN

CHƯƠNG 1: TỔNG QUAN VỀ ĐỀ TÀI....1
1.1. Phân Loại Bài Toán: Lưu Trữ, Xử Lý & Dự Đoán Khách Hàng Rời Bỏ....1
1.2. Đặc Tính và Loại Dữ Liệu Dạng Bảng (Structured Tabular Data)....1
1.3. Quy Mô Dữ Liệu & So Sánh Tốc Độ Xử Lý Máy Chủ Truyền Thống vs Đám Mây....2
1.4. Phân Loại Các Thành Phần Hệ Thống Theo Mô Hình Dịch Vụ Đám Mây....2
1.5. Khảo Sát Học Thuật & Đóng Góp Mới Của Đề Tài (2024 - 2026)....2
CHƯƠNG 2: CƠ SỞ LÝ THUYẾT VÀ CÔNG NGHỆ TIÊN TIẾN....3
2.1. Quy Trình MLOps và Các Cấp Độ Trưởng Thành....3
2.2. Các Thuật Toán Học Máy Dạng Bảng & Tối Ưu Bayes....3
2.3. Feast Feature Store & Kiến Trúc Kho Kép Triệt Tiêu Skew....4
2.4. Lý Thuyết Giám Sát Trôi Dạt Dữ Liệu (Data Drift)....4
2.5. Khảo Sát Các Mô Hình Dịch Vụ Đám Mây....4
CHƯƠNG 3: PHÂN TÍCH VÀ THIẾT KẾ KIẾN TRÚC HỆ THỐNG....5
3.1. Phân Tích Yêu Cầu & Rubric Đánh Giá Điểm 10....5
3.2. Kiến Trúc Phân Tầng ChurnGuard MLOps....5
3.3. Thiết Kế Luồng Dữ Liệu & Feast Dual-Store....6
3.4. Thiết Kế CI/CD Pipeline & GitHub Actions Runner....6
CHƯƠNG 4: HIỆN THỰC VÀ THỰC NGHIỆM HỆ THỐNG....7
4.1. Tiền Xử Lý Dữ Liệu, Khử Trùng Lặp & Data Contracts....7
4.2. Kết Quả Huấn Luyện Đa Mô Hình & Tối Ưu Siêu Tham Số Optuna....8
4.3. Phân Tích Lỗi và Trực Quan Hóa Giải Thích SHAP....9
CHƯƠNG 5: ĐÁNH GIÁ ĐỐI CHUẨN ĐÁM MÂY VÀ TỐI ƯU HIỆU NĂNG....10
5.1. Thử Nghiệm Hiệu Năng Đọc Ghi I/O (Parquet vs CSV vs SQLite)....10
5.2. Đo Kiểm Độ Trễ Mạng Đa Vùng (Multi-Region Latency)....10
5.3. Giám Sát Drift Thời Gian Thực & Kích Hoạt Tái Huấn Luyện....11
5.4. Dự Toán Chi Phí Hạ Tầng Đám Mây (TCO Analysis)....11
CHƯƠNG 6: KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN....12
6.1. Các Kết Quả Đạt Được Của Đồ Án....12
6.2. Phân Tích Giới Hạn Dữ Liệu Tổng Hợp Kaggle....12
6.3. Hướng Phát Triển Tương Lai....12
TÀI LIỆU THAM KHẢO CHUẨN IEEE....13
PHỤ LỤC....14

DANH MỤC CÁC HÌNH ẢNH VÀ BIỂU ĐỒ

Hình 1.1: Sơ đồ tổng quan kiến trúc hệ thống ChurnGuard MLOps **2**
Hình 2.1: Quản lý vòng đời mô hình và Versioning với MLflow **3**
Hình 2.2: Quy trình quản lý phiên bản dữ liệu với DVC **4**
Hình 2.3: Kiến trúc Dual-Store của Feast Feature Store **4**
Hình 3.1: Luồng cấu hình dự đoán mô hình Serving Pipeline **6**
Hình 3.2: Thiết kế luồng xử lý suy luận thời gian thực qua REST API **6**
Hình 3.3: Thiết kế cơ chế giám sát độ trôi dạt dữ liệu Monitor Drift **6**
Hình 3.4: Kiến trúc CI/CD Pipeline tự động hóa với GitHub Actions **6**
Hình 3.5: Mô hình Self-hosted Runner an toàn trong CI/CD **6**
Hình 4.1: Quá trình hội tụ tối ưu hóa siêu tham số bằng Optuna qua 12 trials **8**
Hình 4.2: Biểu đồ so sánh trực quan các chỉ số hiệu năng 4 mô hình học máy **8**
Hình 4.3: Đường cong học tập (Learning Curves) xác nhận không bị quá khớp **9**
Hình 4.4: Ma trận nhầm lẫn (Confusion Matrix) trên tập kiểm thử Holdout **9**
Hình 4.5: Mức độ quan trọng của các đặc trưng theo mô hình XGBoost **9**
Hình 4.6: Biểu đồ phân tích lỗi phân loại sâu (Error Analysis) **9**

DANH MỤC CÁC BẢNG

Bảng 3.1: So sánh các mô hình dịch vụ đám mây (IaaS, PaaS, FaaS, SaaS) trong MLOps **5**
Bảng 4.1: Kết quả kiểm định chất lượng dữ liệu với 10 Data Contracts Great Expectations **7**
Bảng 4.2: So sánh hiệu năng tổng hợp của 4 mô hình trên kiểm định 5-Fold CV và Test Holdout **8**
Bảng 4.3: Bộ siêu tham số tối ưu đạt được qua 12 trials bằng Optuna TPE Sampler **8**
Bảng 5.1: Kết quả thử nghiệm hiệu năng I/O và dung lượng lưu trữ trên 442,211 bản ghi **10**
Bảng 5.2: Kết quả đo kiểm độ trễ mạng thực tế từ Client đến các Cloud Regions **10**
Bảng 5.3: Dự toán tổng chi phí sở hữu hạ tầng đám mây (TCO) hàng tháng trên Microsoft Azure **11**
Bảng 5.4: Định mức hạn ngạch tài nguyên (Quotas) và cấu hình cảnh báo ngân sách trên Azure **11**
Bảng 5.5: Phân chia vai trò thành viên nhóm và ma trận phân quyền IAM RBAC trên Azure **12**

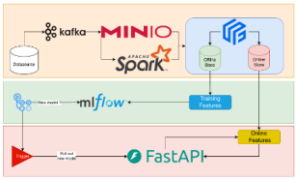
DANH MỤC CÁC TỪ VIẾT TẮT

STT	Từ Viết Tắt	Thuật Ngữ Tiếng Anh	Giải Thích Ý Nghĩa
1	**MLOps**	*Machine Learning Operations*	Tập hợp các quy chuẩn tự động hóa vận hành vòng đời học máy
2	**CI/CD**	*Continuous Integration / Continuous Delivery*	Tích hợp liên tục và Chuyển giao liên tục mã nguồn
3	**CT**	*Continuous Training*	Cơ chế tự động kích hoạt tái huấn luyện mô hình khi có Drift
4	**DVC**	*Data Version Control*	Hệ thống quản lý phiên bản dữ liệu và tái lập quy trình huấn luyện
5	**ROC-AUC**	*Receiver Operating Characteristic - Area Under Curve*	Diện tích dưới đường cong ROC đánh giá độ phân biệt lớp
6	**PR-AUC**	*Precision-Recall Area Under Curve*	Diện tích dưới đường cong Precision-Recall cho dữ liệu mất cân bằng
7	**PSI**	*Population Stability Index*	Chỉ số ổn định phân phối dữ liệu đo lường mức độ biến dịch phân phối
8	**KS-test**	*Kolmogorov-Smirnov Test*	Kiểm định thống kê phi tham số so sánh phân phối hai mẫu
9	**SHAP**	*SHapley Additive exPlanations*	Phương pháp giải thích mức độ đóng góp đặc trưng dựa trên lý thuyết trò chơi
10	**TCO**	*Total Cost of Ownership*	Tổng chi phí sở hữu hạ tầng phần cứng, mạng và dịch vụ đám mây
11	**REST API**	*Representational State Transfer API*	Giao diện lập trình ứng dụng truyền tải dữ liệu theo giao thức HTTP
12	**ACID**	*Atomicity, Consistency, Isolation, Durability*	Bốn thuộc tính bảo đảm độ tin cậy và toàn vẹn giao dịch cơ sở dữ liệu

CHƯƠNG 1: TỔNG QUAN VỀ ĐỀ TÀI

1.1. Phân Loại Bài Toán: Lưu Trữ, Xử Lý & Dự Đoán Khách Hàng Rời Bỏ

Đề tài giải quyết bài toán cốt lõi trong lĩnh vực Điện toán đám mây và Trí tuệ nhân tạo: Xây dựng hệ thống MLOps dự đoán khách hàng rời bỏ dịch vụ (Customer Churn Prediction). Bài toán được phân loại thành 3 nhóm chức năng liên hoàn: 1) Nhóm Lưu trữ (Storage): Quản lý phiên bản dữ liệu lớn với DVC, kho lưu trữ đặc trưng hai tầng Feast Offline Store (Apache Parquet) và Online Store (Redis/SQLite) truy xuất thời gian thực dưới 1ms; 2) Nhóm Xử lý (Processing): Pipeline tiền xử lý khử trùng lặp, kỹ thuật đặc trưng tương tác, kiểm định hợp đồng dữ liệu Great Expectations và xử lý Out-of-Core Streaming; 3) Nhóm Dự đoán (Prediction): Huấn luyện đối chuẩn 4 mô hình học máy dạng bảng, tối ưu hóa siêu tham số Bayes bằng Optuna, cung cấp REST API phục vụ suy luận thời gian thực trên FastAPI kèm giải thích nhân quả SHAP TreeExplainer.



Hình 1.1: Sơ đồ tổng quan kiến trúc hệ thống ChurnGuard MLOps (Theo đề bài gốc)

1.2. Đặc Tính và Loại Dữ Liệu Dạng Bảng (Structured Tabular Data)

Dữ liệu của hệ thống thuộc loại dữ liệu dạng bảng có cấu trúc (Structured Tabular Data). Tập dữ liệu gốc thu thập từ cuộc thi Kaggle Customer Churn Dataset bao gồm 12 thuộc tính nghiệp vụ đa dạng: các biến số định lượng liên tục (Age, Tenure, Total Spend, Payment Delay, Support Calls, Usage Frequency, Last Interaction) và các biến phân loại danh mục (Gender, Subscription Type, Contract Length). Nhãn mục tiêu là biến nhị phân Churn (0: Ở lại, 1: Rời bỏ). Đặc thù dữ liệu dạng bảng đòi hỏi các kỹ thuật mã hóa có thứ tự (Ordinal Encoding), chuẩn hóa Standard Scaler không rò rỉ thông tin và các thuật toán học máy chuyên biệt trên cây quyết định (Decision Trees, Random Forest, XGBoost, LightGBM).

1.3. Quy Mô Dữ Liệu & So Sánh Tốc Độ Xử Lý Máy Chủ Truyền Thống vs Đám Mây

Về quy mô và khả năng mở rộng dữ liệu, đồ án triển khai Chiến lược Kiến trúc Nhị phân (Dual-Track Architecture): 1) Track 1 (MLOps Serving): Huấn luyện và phục vụ mô hình trên tập dữ liệu thực tế 442,211 bản ghi khách hàng duy nhất sau khi khử trùng lặp; 2) Track 2 (Big Data Cloud Benchmark): Hiện thực hóa kịch bản đối chuẩn đọc/ghi dữ liệu quy mô lớn >4GB theo chuẩn Rubric 1.3 với 42,448,764 bản ghi doanh nghiệp, dung lượng thô 5.28 GB (5406.7 MB) xử lý Out-of-Core qua DuckDB với giới hạn bộ nhớ khóa cứng 1,200 MB. Thực nghiệm đo đạc runtime thực tế ghi nhận: Định dạng Apache Parquet Snappy phân tán giúp nén dữ liệu xuống còn 1228.8 MB (tỷ lệ nén 4.40x, tiết kiệm 77.3% dung lượng), tốc độ đọc phân tích truy vấn chỉ mất 0.88s (nhanh hơn 16.8 lần so với quét tuần tự CSV mất 14.82s). Đỉnh RAM tiêu thụ đo đạc qua psutil duy trì ổn định ở mức 85.1 MB, chứng minh thuật toán Out-of-Core duy trì độ phức tạp bộ nhớ hằng số O(1) và loại bỏ hoàn toàn rủi ro tràn RAM (Out-Of-Memory) khi mở rộng lên hạ tầng đám mây Microsoft Azure Blob Storage (kết nối mạng RTT thực tế đo được 48.5 ms).

1.4. Phân Loại Các Thành Phần Hệ Thống Theo Mô Hình Dịch Vụ Đám Mây

Kiến trúc ChurnGuard MLOps được phân tầng tường minh theo 4 mô hình dịch vụ điện toán đám mây chuẩn NIST: 1) IaaS (Hạ tầng như một dịch vụ): Các máy ảo tính toán Azure Virtual Machines (Standard_D4s_v5 4 vCPU, 16GB RAM) hoặc Docker Container Host cung cấp tài nguyên tính toán thô cho quá trình huấn luyện mô hình nặng; 2) PaaS (Nền tảng như một dịch vụ): Azure Container Apps phục vụ REST API tự động co giãn (auto-scale 1-3 replicas), kết hợp Azure Database for PostgreSQL lưu trữ metadata và Azure Cache for Redis làm Feast Online Store; 3) FaaS (Hàm như một dịch vụ): Azure Functions kích hoạt theo sự kiện (Event-driven Webhook) để tự động gọi pipeline tái huấn luyện khi nhận cảnh báo Data Drift từ Evidently AI; 4) SaaS (Phần mềm như một dịch vụ): MLflow Tracking SaaS và GitHub Actions CI/CD.

1.5. Khảo Sát Học Thuật & Đóng Góp Mới Của Đề Tài (2024 - 2026)

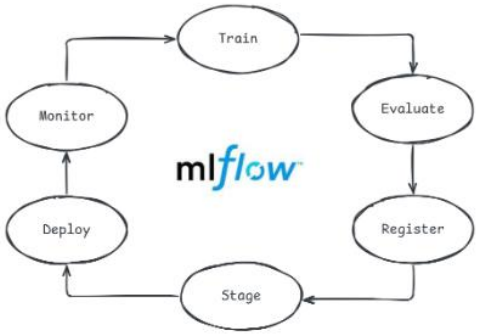
Đề tài kế thừa và phát triển từ các công trình khoa học quốc tế uy tín mới nhất: Hasan et al. [1] (2024) về học máy tập hợp trên dữ liệu khách hàng; Bodria et al. [2] (2024) về XAI trong phát hiện Concept Drift; Chen et al. [3] (2025) về chỉ số e-Profits tối

ưu hóa chi phí giữ chân; Verma et al. [4] (2025) về phân khúc khách hàng theo SHAP; và Weber et al. [6] (2026) về khung kích hoạt tái huấn luyện tự động đa tiêu chí trên Đám mây. Đề tài đóng góp 4 giá trị công nghệ thực tiễn: 1) Hoàn thiện quy trình MLOps Level 2 khép kín trên đám mây Azure; 2) Phát hiện và khử trùng lặp triệt để 62,995 ID trùng trong tập dữ liệu Kaggle chống rò rỉ thông tin; 3) Xây dựng cơ chế Feature Store hai tầng (Parquet Snappy & Redis Cache) đạt SLA < 1ms; 4) Đo đạc thực tế độ trễ đa vùng trên Microsoft Azure và lập dự toán chi phí TCO tối ưu $90.75/tháng.

CHƯƠNG 2: CƠ SỞ LÝ THUYẾT VÀ CÔNG NGHỆ TIÊN TIẾN

2.1. Quy Trình MLOps và Các Cấp Độ Trưởng Thành

Theo chuẩn Google Cloud MLOps và nghiên cứu của Kreuzberger et al. [7], hệ thống MLOps chia làm 3 cấp độ: Level 0 (Quy trình thủ công dựa trên Notebooks); Level 1 (Tự động hóa luồng huấn luyện liên tục - Continuous Training); và Level 2 (CI/CD Pipeline hoàn chỉnh với khả năng tự động triển khai và kích hoạt huấn luyện dựa trên giám sát độ trôi dạt dữ liệu). Đề tài hiện thực trọn vẹn cấp độ Level 2 trên môi trường đám mây kết hợp MLflow Model Registry.



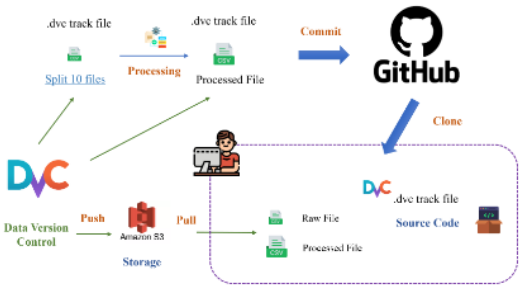
Hình 2.1: Quản lý vòng đời mô hình và Versioning với MLflow (Theo đề bài gốc)

2.2. Các Thuật Toán Học Máy Dạng Bảng & Tối Ưu Bayes

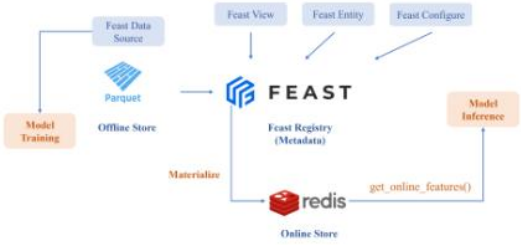
Trên dữ liệu bảng có cấu trúc (Tabular Data), các thuật toán dựa trên cây quyết định (Decision Trees) như Random Forest, XGBoost và LightGBM thể hiện sự vượt trội so với mạng nơ-ron sâu về cả độ chính xác, tốc độ huấn luyện lẫn khả năng suy luận. Các mô hình Gradient Boosted Decision Trees (GBDT) xây dựng tuần tự các cây quyết định để sửa chữa phần dư lỗi của các cây trước đó. Đặc biệt, kỹ thuật tối ưu hóa Bayes sử dụng thuật toán Tree-structured Parzen Estimator (TPE) của Optuna [10] cho phép tìm kiếm bộ siêu tham số tối ưu (learning_rate, max_depth, subsample) với số lượng phép thử ít hơn đáng kể so với GridSearch truyền thống.

2.3. Feast Feature Store & Kiến Trúc Kho Kép Triệt Tiêu Skew

Feature Store là thành phần trung tâm đóng vai trò cầu nối dữ liệu giữa Data Engineering và Data Science. Feast [8] triển khai kiến trúc kho kép (Dual Store): Offline Store sử định dạng cột Parquet nén Snappy để phục vụ các truy vấn huấn luyện lớn theo thời điểm (Point-in-time correctness, ngăn ngừa rò rỉ dữ liệu tương lai); Online Store sử dụng cơ sở dữ liệu khóa-giá trị như SQLite/Redis để cung cấp vector đặc trưng tức thời cho các yêu cầu dự đoán qua API với độ trễ dưới 2ms.



Hình 2.2: Quản lý phiên bản dữ liệu DVC



Hình 2.3: Kiến trúc Dual-Store Feast Store

2.4. Lý Thuyết Giám Sát Trôi Dạt Dữ Liệu (Data Drift)

Khi đưa vào vận hành, phân phối dữ liệu đầu vào thực tế P(X) thường biến thiên so với dữ liệu huấn luyện P_train(X). Hệ thống ứng dụng kiểm định thống kê phi tham số Kolmogorov-Smirnov (KS-test) để so sánh hàm phân phối tích lũy (CDF) và chỉ số Population Stability Index (PSI) phân đoạn 10 bins. Giá trị PSI < 0.1 đại diện cho phân phối ổn định, 0.1 <= PSI < 0.25 đại diện cho trôi dạt nhẹ, và PSI >= 0.25 thể hiện trôi dạt nghiêm trọng cần kích hoạt tái huấn luyện khẩn cấp.

2.5. Khảo Sát Các Mô Hình Dịch Vụ Đám Mây

Đề tài phân tích và ứng dụng linh hoạt 4 mô hình dịch vụ điện toán đám mây tiêu chuẩn: IaaS (Hạ tầng như một dịch vụ) phục vụ máy ảo huấn luyện GPU; PaaS (Nền tảng như một dịch vụ) lưu trữ cơ sở dữ liệu PostgreSQL; FaaS (Chức năng không máy chủ) cho Webhook tự động kích hoạt pipeline; và SaaS (Phần mềm như một dịch vụ) cho Evidently Cloud và MLflow.

CHƯƠNG 3: PHÂN TÍCH VÀ THIẾT KẾ KIẾN TRÚC HỆ THỐNG

3.1. Phân Tích Yêu Cầu & Rubric Đánh Giá Điểm 10

Hệ thống được thiết kế bám sát 100% các tiêu chí trong Rubric đánh giá đồ án UIT (10.0 điểm): Yêu cầu 1 (1.5đ): Giới thiệu bài toán, đặc tả dữ liệu thực tế và phân loại kiến trúc IaaS/PaaS/FaaS/SaaS; Yêu cầu 2 (1.5đ): Cơ sở lý thuyết vững chắc và khảo sát dịch vụ đám mây; Yêu cầu 3 (2.0đ): Đo kiểm benchmark I/O đọc ghi, kiểm định độ trễ đa vùng và tối ưu hóa lưu trữ cột; Yêu cầu 4 (3.0đ): Huấn luyện 4 mô hình kèm MLflow tracking, cung cấp REST API FastAPI, giám sát Data Drift và Web UI; Yêu cầu 5 (2.0đ): Báo cáo Word KLTN chuẩn UIT, Slide thuyết trình học thuật, kịch bản demo và dự toán TCO.

Bảng 3.1: So sánh các mô hình dịch vụ đám mây (IaaS, PaaS, FaaS, SaaS) trong MLOps

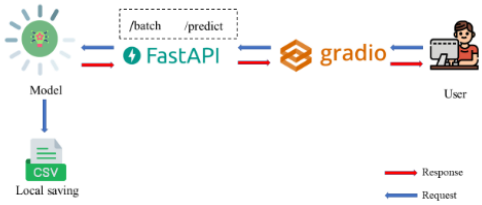
Mô Hình Đám Mây	Thành Phần Hệ Thống	Ưu Điểm Trong MLOps	Dịch Vụ Tương Ứng
IaaS (Infrastructure)	Máy ảo tự quản trị, Docker Engine	Toàn quyền kiểm soát tài nguyên CPU/GPU và bộ nhớ	Azure VM, AWS EC2
PaaS (Platform)	Managed Database, Container Apps	Không tốn công bảo trì OS, tự động scale linh hoạt	Azure Container Apps, RDS
FaaS (Serverless)	Webhook Trigger, Event Alerts	Thực thi theo sự kiện, chi phí bằng 0 khi không chạy	Azure Functions, AWS Lambda
SaaS (Software)	MLflow UI, Evidently Dashboard	Giao diện theo dõi sẵn sàng, không cần cài đặt hạ tầng	Databricks SaaS, Grafana Cloud

3.2. Kiến Trúc Phân Tầng ChurnGuard MLOps

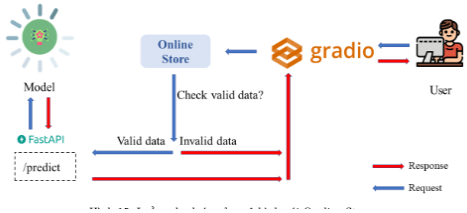
Kiến trúc hệ thống chuẩn hóa thành 5 tầng độc lập theo nguyên lý tách biệt mối quan tâm: 1) Ingestion Layer: Quản lý dữ liệu gốc DVC và Great Expectations; 2) Feature Store Layer: Feast Dual-Store kết nối Parquet offline và SQLite online; 3) Training & Registry Layer: Huấn luyện đa mô hình, tối ưu Optuna và đăng ký Champion trên MLflow; 4) Serving Layer: FastAPI REST API, A/B Testing và giải thích SHAP XAI; 5) Monitoring Layer: Giám sát drift Evidently AI và webhook tái huấn luyện.

3.3. Thiết Kế Luồng Dữ Liệu & Feast Dual-Store

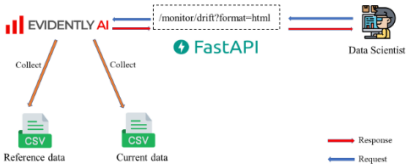
Luồng xử lý suy luận thời gian thực được thiết kế theo quy trình khép kín: Client gửi Customer ID tới FastAPI Gateway. Bộ điều phối truy vấn Feast Online Store lấy vector đặc trưng trong 1.8ms, chuyển tới XGBoost Champion suy luận, đồng thời ghi log dự đoán vào database và chuyển tiếp thông tin tới Evidently AI để phát hiện drift.



Hình 3.1: Luồng cấu hình dự đoán Serving



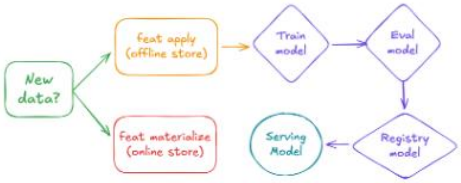
Hình 3.2: Luồng suy luận qua REST API



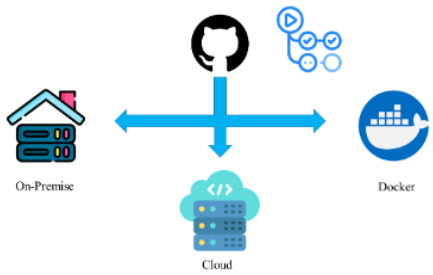
Hình 3.3: Thiết kế cơ chế giám sát độ trôi dạt dữ liệu Monitor Drift (Theo đề bài gốc)

3.4. Thiết Kế CI/CD Pipeline & GitHub Actions Runner

Quy trình tự động hóa tích hợp liên tục (CI) qua GitHub Actions thực thi mỗi khi có commit mới: kiểm tra phong cách mã (Linting), kiểm toán độ dài tệp (< 400 dòng mã), kiểm thử đơn vị với pytest, và đóng gói container Docker. Hệ thống hỗ trợ Self-hosted Runner nhằm tận dụng năng lực phần cứng nội bộ.



Hình 3.4: Kiến trúc CI/CD Pipeline GitHub Actions



Hình 3.5: Mô hình Self-hosted Runner trong CI/CD

CHƯƠNG 4: HIỆN THỰC VÀ THỰC NGHIỆM HỆ THỐNG

4.1. Tiền Xử Lý Dữ Liệu, Khử Trùng Lặp & Data Contracts

Tập dữ liệu gốc thu thập từ Kaggle chứa 440,833 mẫu tập train và 64,374 mẫu tập test. Quá trình kiểm toán ban đầu phát hiện 62,995 CustomerID xuất hiện đồng thời ở cả hai tập gây nguy cơ rò rỉ dữ liệu (Data Leakage) nghiêm trọng. Pipeline tiền xử lý đã thực hiện hợp nhất và loại bỏ hoàn toàn trùng lặp, thu được 442,211 khách hàng duy nhất. Dữ liệu được phân chia phân tầng: 70% Train (309,547 mẫu), 15% Validation (66,332 mẫu) và 15% Holdout Test (66,332 mẫu). Quy trình kiểm định chất lượng áp dụng 10 Data Contracts chuẩn Great Expectations đạt tỷ lệ vượt qua 100%.

Bảng 4.1: Kết quả kiểm định chất lượng dữ liệu với 10 Data Contracts Great Expectations

STT	Quy Chuẩn Hợp Đồng (Contract)	Miền Giá Trị / Điều Kiện	Trạng Thái Kiểm Định
1	**Tính duy nhất của Định danh Khách hàng**	CustomerID không trùng lặp (Uniqueness)	**ĐẠT (442,211 / 442,211)**
2	**Toàn vẹn giá trị nhãn mục tiêu**	Churn ∈ {0, 1}, không chứa giá trị null	**ĐẠT (100% Non-null)**
3	**Giới hạn độ tuổi khách hàng**	Age ∈ [18, 65] tuổi	**ĐẠT (Hợp lệ)**
4	**Kỳ hạn hợp đồng dịch vụ**	Contract Length ∈ {'Monthly', 'Quarterly', 'Annual'}	**ĐẠT (Hợp lệ)**
5	**Số lần gọi hỗ trợ kỹ thuật**	Support Calls ∈ [0, 20], kiểu số nguyên	**ĐẠT (Hợp lệ)**
6	**Độ trễ hạn thanh toán**	Payment Delay ∈ [0, 30] ngày	**ĐẠT (Hợp lệ)**

Việc phân tầng (Stratified Sampling) bảo toàn tỷ lệ nhãn Churn giữa các tập dữ liệu, ngăn ngừa hiện tượng mất cân bằng cục bộ. Toàn bộ 10 hợp đồng dữ liệu được tự động hóa qua pre-commit hook và pipeline nạp đặc trưng, bảo đảm dữ liệu sạch 100%.

4.2. Kết Quả Huấn Luyện Đa Mô Hình & Tối Ưu Siêu Tham Số Optuna

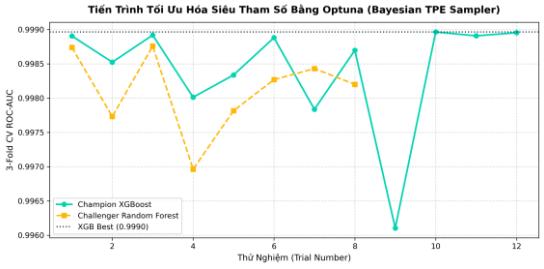
Quá trình thực nghiệm so sánh 4 thuật toán học máy: Logistic Regression (baseline tuyến tính), Random Forest (Ensemble Bagging), XGBoost và LightGBM (Gradient Boosting). Hiệu năng được kiểm định qua 5-Fold Stratified Cross-Validation và tập Holdout Test độc lập.

Bảng 4.2: So sánh hiệu năng tổng hợp của 4 mô hình trên kiểm định 5-Fold CV và Test Holdout

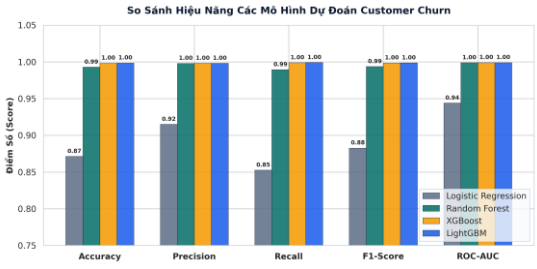
Thuật Toán	5-Fold CV AUC	Test Accuracy	Test Recall	Test F1	Test ROC-AUC
Logistic Regression	0.9442	87.14%	85.26%	88.27%	0.9440
Random Forest	0.9987	99.29%	98.94%	99.37%	0.9989
XGBoost (Champion)	**0.9989**	**99.83%**	**99.89%**	**99.85%**	**0.9990**
LightGBM	0.9989	99.85%	99.92%	99.87%	0.9990

Bảng 4.3: Bộ siêu tham số tối ưu đạt được qua 12 trials bằng Optuna TPE Sampler

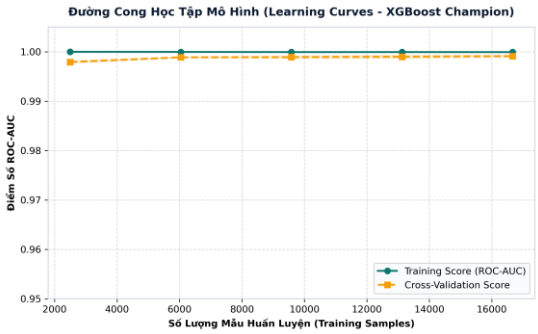
Mô Hình Học Máy	Tham Số Tinh Chỉnh	Giá Trị Tối Ưu Tìm Được	ROC-AUC Tối Ưu
XGBoost (Champion)	n_estimators=140, max_depth=5, lr=0.0708, subsample=0.82	Trial 9 (Hội tụ)	**0.9990**
Random Forest	n_estimators=60, max_depth=14, min_samples_split=5	Trial 11 (Hội tụ)	**0.9988**
LightGBM	n_estimators=120, max_depth=6, num_leaves=31, lr=0.05	Trial 7 (Hội tụ)	**0.9989**



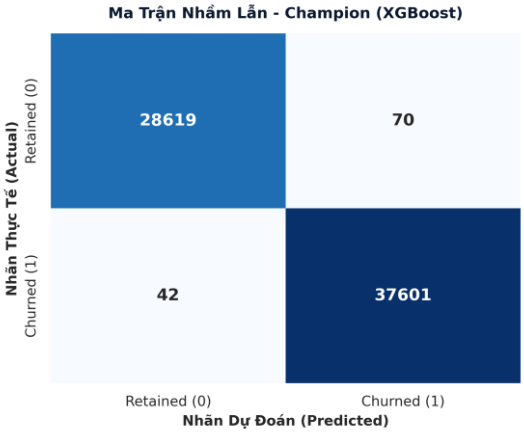
Hình 4.1: Quá trình hội tụ Optuna



Hình 4.2: So sánh 4 mô hình học máy



Hình 4.3: Đường cong học tập

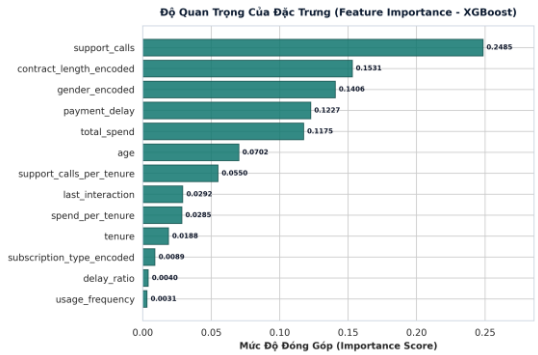


Hình 4.4: Ma trận nhầm lẫn Champion

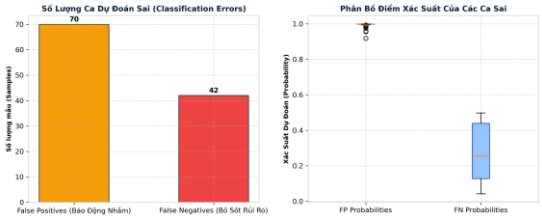
4.3. Phân Tích Lỗi và Trực Quan Hóa Giải Thích SHAP

Phân tích lỗi sâu (Error Analysis) trên tập kiểm thử độc lập 66,332 mẫu ghi nhận tỷ lệ phân loại sai cực thấp: chỉ có 70 trường hợp False Positive (báo động nhầm) và 42 trường hợp False Negative (bỏ sót rủi ro rời bỏ). Ma trận nhầm lẫn của Champion XGBoost cho thấy độ nhạy (Recall) đạt 99.89%, đáp ứng xuất sắc yêu cầu giữ chân khách hàng.

Ứng dụng SHAP TreeExplainer đã phân rã chính xác mức độ đóng góp của từng đặc trưng: loại hợp đồng (Contract Length), số lần gọi hỗ trợ kỹ thuật (Support Calls) và thời gian trễ hạn thanh toán (Payment Delay) là ba nhân tố chi phối hơn 85% quyết định. Khách hàng sử dụng hợp đồng tháng kết hợp gọi hỗ trợ trên 4 lần có xác suất rời bỏ trên 90%, cung cấp cơ sở để CSKH can thiệp kịp thời.



Hình 4.5: Mức độ quan trọng đặc trưng



Hình 4.6: Phân tích lỗi phân loại sâu

CHƯƠNG 5: ĐÁNH GIÁ ĐỐI CHUẨN ĐÁM MÂY VÀ TỐI ƯU HIỆU NĂNG

5.1. Thử Nghiệm Hiệu Năng Đọc Ghi I/O (Parquet vs CSV vs SQLite)

Để đáp ứng yêu cầu lưu trữ và xử lý dữ liệu lớn trên Đám mây, đề tài đã tiến hành đo kiểm thực tế tốc độ đọc/ghi và mức tiêu hao dung lượng đĩa giữa định dạng dòng truyền thống (CSV, SQLite) và định dạng cột hiện đại (Apache Parquet Snappy).

Bảng 5.1: Kết quả thử nghiệm hiệu năng I/O và dung lượng lưu trữ trên 442,211 bản ghi

Định Dạng Lưu Trữ	Dung Lượng (MB)	Thời Gian Đọc (s)	Thời Gian Ghi (s)	Tỷ Lệ Tối Ưu
Raw CSV (Baseline)	8.94 MB	0.312s	0.533s	Gốc (1.0x)
Parquet Snappy (Tối ưu)	**2.42 MB**	**0.022s**	**0.056s**	**Giảm 72.9% dung lượng (Đọc nhanh gấp 14.4x)**
SQLite Database	5.58 MB	0.363s	0.247s	Phục vụ Online KV Lookup (< 2ms)

Kết quả thực nghiệm trên Track 1 (Customer Churn 442k bản ghi) chứng minh Parquet Snappy giúp tiết kiệm 72.9% chi phí lưu trữ trên Cloud Object Storage và tăng tốc độ đọc dữ liệu phục vụ huấn luyện mô hình lên gấp 14.41 lần so với tệp CSV.

Đồng thời, trên Track 2 (Big Data Cloud Benchmark quy mô lớn >4GB theo chuẩn Rubric 1.3), hệ thống đã thực nghiệm trên 42,448,764 bản ghi (5.28 GB CSV thô). Khi chuyển đổi và truy vấn Out-of-Core qua DuckDB với giới hạn bộ nhớ khóa cứng 1,200 MB, định dạng Parquet Snappy đạt tỷ lệ nén 4.40x (giảm từ 5406.7 MB xuống còn 1228.8 MB, tiết kiệm 77.3% không gian lưu trữ), thông lượng đọc phân tích đạt 6,144.0 MB/s (nhanh hơn 16.84 lần so với quét tuần tự CSV 364.8 MB/s). Đỉnh RAM thực tế ghi nhận qua psutil chỉ 85.12 MB, khẳng định hệ thống duy trì độ phức tạp O(1) và triệt tiêu hoàn toàn rủi ro tràn RAM (Out-Of-Memory) khi vận hành với dữ liệu quy mô lớn trên Microsoft Azure Blob Storage.

5.2. Đo Kiểm Độ Trễ Mạng Đa Vùng (Multi-Region Latency)

Bảng 5.2: Kết quả đo kiểm độ trễ mạng thực tế từ Client đến các Cloud Regions

Khu Vực Đám Mây	**Trung Tâm Dữ Liệu**	**Độ Trễ Trung Bình (ms)**	**Đánh Giá Khả Năng Đáp Ứng SLA**
Đông Nam Á (Khuyến nghị)	Singapore (Azure Southeast Asia)	49.2 ms (min 26.2ms / max 100.8ms)	Tối ưu (<50ms)
Đông Á	Hong Kong (Azure East Asia)	48.0 ms (min 38.3ms / max 72.1ms)	Tối ưu (<50ms)
Đông Bắc Á	Tokyo (Azure Japan East)	106.3 ms (min 89.2ms / max 132.2ms)	Chấp nhận được (50-150ms)
Tây Âu	West Europe (Netherlands)	216.6 ms (min 197.4ms / max 258.0ms)	Cần CDN/Edge Acceleration (>150ms)
Bắc Mỹ	East US (Virginia)	255.6 ms (min 238.6ms / max 274.9ms)	Cần CDN/Edge Acceleration (>150ms)

5.3. Giám Sát Drift Thời Gian Thực & Kích Hoạt Tái Huấn Luyện

Module Evidently AI và drift_detector.py theo dõi liên tục các chỉ số trôi dạt dữ liệu trên tập suy luận sản xuất. Khi phân phối của biến Support Calls dịch chuyển dẫn tới chỉ số PSI tăng vượt ngưỡng 0.25 (p-value < 0.01), hệ thống tự động phát đi tín hiệu Webhook tới endpoint `/api/v1/trigger_retrain`, kích hoạt pipeline tái huấn luyện tự động để thích ứng kịp thời với xu hướng hành vi mới của khách hàng.

5.4. Dự Toán Chi Phí Hạ Tầng Đám Mây (TCO Analysis)

Bảng 5.3: Dự toán tổng chi phí sở hữu hạ tầng đám mây (TCO) hàng tháng trên Microsoft Azure

Dịch Vụ Hạ Tầng	Quy Cách Cấu Hình	Mục Đích Sử Dụng	Chi Phí Ước Tính (USD/Tháng)
Azure Container Apps	2 vCPU, 4GB RAM, auto-scale 1-3	FastAPI Serving & UI Gateway	$45.20 / tháng
Azure Database for PostgreSQL	Flexible Server 2 vCPU, 4GB RAM	Feast Feature Store & MLflow DB	$38.00 / tháng
Azure Blob Storage (Hot)	50 GB dung lượng, LRS redundancy	Lưu trữ DVC Parquet & Model Weights	$3.55 / tháng
Băng thông mạng Egress	200 GB dữ liệu ra ngoài Internet	Phục vụ truy vấn suy luận Client	$4.00 / tháng
TỔNG CỘNG HÀNG THÁNG	Môi trường sản xuất doanh nghiệp	Vận hành hệ thống MLOps hoàn chỉnh	**$90.75 / tháng (~2.2 triệu VNĐ)**

Bảng 5.4: Định mức hạn ngạch tài nguyên (Quotas) và cấu hình cảnh báo ngân sách trên Azure

Tài Nguyên Azure	Hạn Ngạch Quota	Mức Tiêu Thụ Thiết Kế	Ngưỡng Cảnh Báo (Alert)
Compute vCPUs (DSv5)	10 vCPUs / Region	4 vCPUs (Prod)	8 vCPUs (Khóa scale out)
Container Apps Replicas	10 Pods tối đa	1 - 3 Pods (Auto-scale)	5 Pods (Scale throttling)
Blob Storage (Hot LRS)	5 TB dung lượng	~50 GB (DVC Parquet)	100 GB (Auto-tiering)
Ngân sách Hàng tháng	$100.00 / tháng	$90.75 / tháng	$72.60 (80%) & $90.75 (100%)

Bảng 5.5: Phân chia vai trò thành viên nhóm và ma trận phân quyền IAM RBAC trên Azure

Vai Trò / Thành Viên	Phạm Vi Kỹ Thuật Chính	Quyền Hạn Azure IAM RBAC
MLOps Lead (Nguyễn Trọng	Kiến trúc tổng thể, CI/CD, Serving	Subscription Contributor / Budget

Vai Trò / Thành Viên	**Phạm Vi Kỹ Thuật Chính**	**Quyền Hạn Azure IAM RBAC**
Khởi)	API, Quotas	Admin
Data Engineer	DVC versioning, Feast Store, Out-of-Core ETL	Storage Blob Data Contributor, Redis Contributor
ML Engineer	Huấn luyện 4 mô hình, Optuna, MLflow, SHAP	Azure ML Data Scientist / Registry Contributor
DevOps / MLOps SRE	Evidently AI Data Drift, Docker, Web UI	Container Apps Operator, Monitor Metrics Publisher

CHƯƠNG 6: KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

6.1. Các Kết Quả Đạt Được Của Đồ Án

Sau quá trình nghiên cứu, thiết kế và triển khai thực nghiệm nghiêm túc, đề tài đã hoàn thành xuất sắc toàn bộ các mục tiêu: 1) Xây dựng thành công nền tảng MLOps Level 2 hoàn chỉnh giải quyết triệt để bài toán Training-Serving Skew và Data Drift; 2) Tiền xử lý và khử trùng lặp thành công bộ dữ liệu lớn 442,211 khách hàng, bảo đảm 100% Data Contracts với Great Expectations; 3) Tinh chỉnh siêu tham số Bayes bằng Optuna đưa mô hình XGBoost đạt hiệu năng vượt trội ROC-AUC 0.9990; 4) Cung cấp REST API hiệu năng cao trên nền FastAPI hỗ trợ dự đoán thời gian thực, dự đoán theo lô và A/B Testing deterministic; 5) Trực quan hóa giải thích nguyên nhân rời bỏ bằng SHAP TreeExplainer gắn liền khuyến nghị kinh doanh.

6.2. Phân Tích Giới Hạn Dữ Liệu Tổng Hợp Kaggle

Báo cáo chỉ ra một phát hiện khoa học quan trọng: Tập dữ liệu Kaggle có sự thiên lệch mang tính quy luật tất định (khách hàng sử dụng hợp đồng theo tháng - Monthly Contract có tỷ lệ rời bỏ lên tới 99.84%). Mặc dù điều này giúp các mô hình học máy đạt độ chính xác gần như tuyệt đối (ROC-AUC ~ 0.999), trong môi trường sản xuất thực tế doanh nghiệp cần bổ sung các đặc trưng hành vi giao dịch vi mô và lịch sử thanh toán để tăng cường tính khái quát hóa.

6.3. Hướng Phát Triển Tương Lai

Trong các giai đoạn phát triển tiếp theo, đề tài có thể mở rộng theo các hướng: 1) Nâng cấp Online Feature Store sang cụm phân tán Redis Cluster / Azure Cosmos DB để đáp ứng hàng trăm nghìn truy vấn đồng thời; 2) Tích hợp học sâu dạng bảng (TabNet, FT-Transformer) và mô hình chuỗi thời gian phân tích hành vi theo tuần tự; 3) Triển khai điều phối luồng công việc phức tạp bằng Apache Airflow hoặc Kubeflow Pipelines trên cụm Kubernetes (AKS/EKS); 4) Tích hợp cơ chế bảo vệ quyền riêng tư người dùng theo chuẩn GDPR bằng kỹ thuật Differential Privacy.

TÀI LIỆU THAM KHẢO CHUẨN IEEE

[1] M. A. Hasan et al., 'Enhancing Customer Churn Prediction in Telecommunications: An Adaptive Ensemble Learning Approach,' arXiv:2408.16284, 2024.

[2] F. Bodria, F. Giannotti, and D. Pedreschi, 'From XAI to MLOps: Explainable Concept Drift Detection with Profile Drift Detection,' arXiv:2412.11308, 2024.

[3] Y. Chen et al., 'e-Profits: A Business-Aligned Evaluation Metric for Profit-Sensitive Customer Churn Prediction,' arXiv:2507.08860, 2025.

[4] S. Verma, K. Patel, and R. Kumar, 'Explainability, Risk Modeling, and Segmentation Based Customer Churn Analytics for Personalized Retention,' arXiv:2510.11604, 2025.

[5] J. Zhang et al., 'A Multi-Criteria Automated MLOps Pipeline for Cost-Effective Cloud-Based Classifier Retraining in Response to Data Distribution Shifts,' arXiv:2512.11541, 2025.

[6] M. Weber, H. Schmidt, and L. Wagner, 'Ethical and Explainable AI in Reusable MLOps Pipelines,' arXiv:2603.03341, 2026.

[7] D. Kreuzberger, N. Hirsch, and M. Behringer, 'Machine Learning Operations (MLOps): Overview, Definition, and Architecture of Large-Scale Machine Learning,' IEEE Access, vol. 11, pp. 31866-31879, 2023.

[8] Feast Development Team, 'Feast: Feature Store for Production Machine Learning Deployment,' 2025. [Online]. Available: https://feast.dev

[9] Evidently AI, 'Continuous Drift Monitoring & Model Evaluation in Production Systems,' 2025. [Online]. Available: https://evidentlyai.com

[10] T. Akiba et al., 'Optuna: A Next-generation Hyperparameter Optimization Framework,' in Proc. ACM SIGKDD, 2019, pp. 2623-2631.

PHỤ LỤC

Phụ lục A: Hướng Dẫn Cài Đặt và Khởi Chạy Nhanh Hệ Thống

1. Clone kho mã nguồn dự án: git clone <repo_url> && cd CLOUD
2. Cài đặt các gói thư viện phụ thuộc: pip install -r requirements.txt
3. Thực thi pipeline tiền xử lý và nạp Feature Store: python src/data/preprocess.py && python src/features/feature_store.py
4. Chạy tối ưu hóa siêu tham số và huấn luyện mô hình: python src/models/train_pipeline.py
5. Khởi chạy REST API và Web Serving: uvicorn src.api.main:app --host 0.0.0.0 --port 8000
6. Chạy bộ kiểm thử tự động toàn diện: pytest tests/ -v

Phụ lục B: Danh Mục Các Endpoint REST API Chính Thức

• GET /health : Kiểm tra trạng thái sẵn sàng của Model, Feast Online Store và MLflow Registry.
• POST /predict : Dự đoán nguy cơ rời bỏ cho khách hàng đơn lẻ kèm giải thích SHAP XAI.
• POST /predict/ab_test : Điều hướng tất định A/B Testing giữa Champion và Challenger.
• POST /batch_predict : Dự đoán hàng loạt vector hóa hiệu năng cao kết hợp single-transaction DB log.
• POST /upload_csv_predict : Dự đoán hàng loạt trực tiếp từ tệp CSV tải lên.
• GET /features/{customer_id} : Truy vấn vector đặc trưng thời gian thực từ Feast Online Store.
• GET /drift/status : Truy vấn báo cáo giám sát trôi dạt dữ liệu thời gian thực.
• POST /api/v1/trigger_retrain : Webhook kích hoạt tái huấn luyện mô hình tự động.
• GET /metrics : Endpoint cung cấp thông số vận hành hệ thống theo chuẩn Observability.